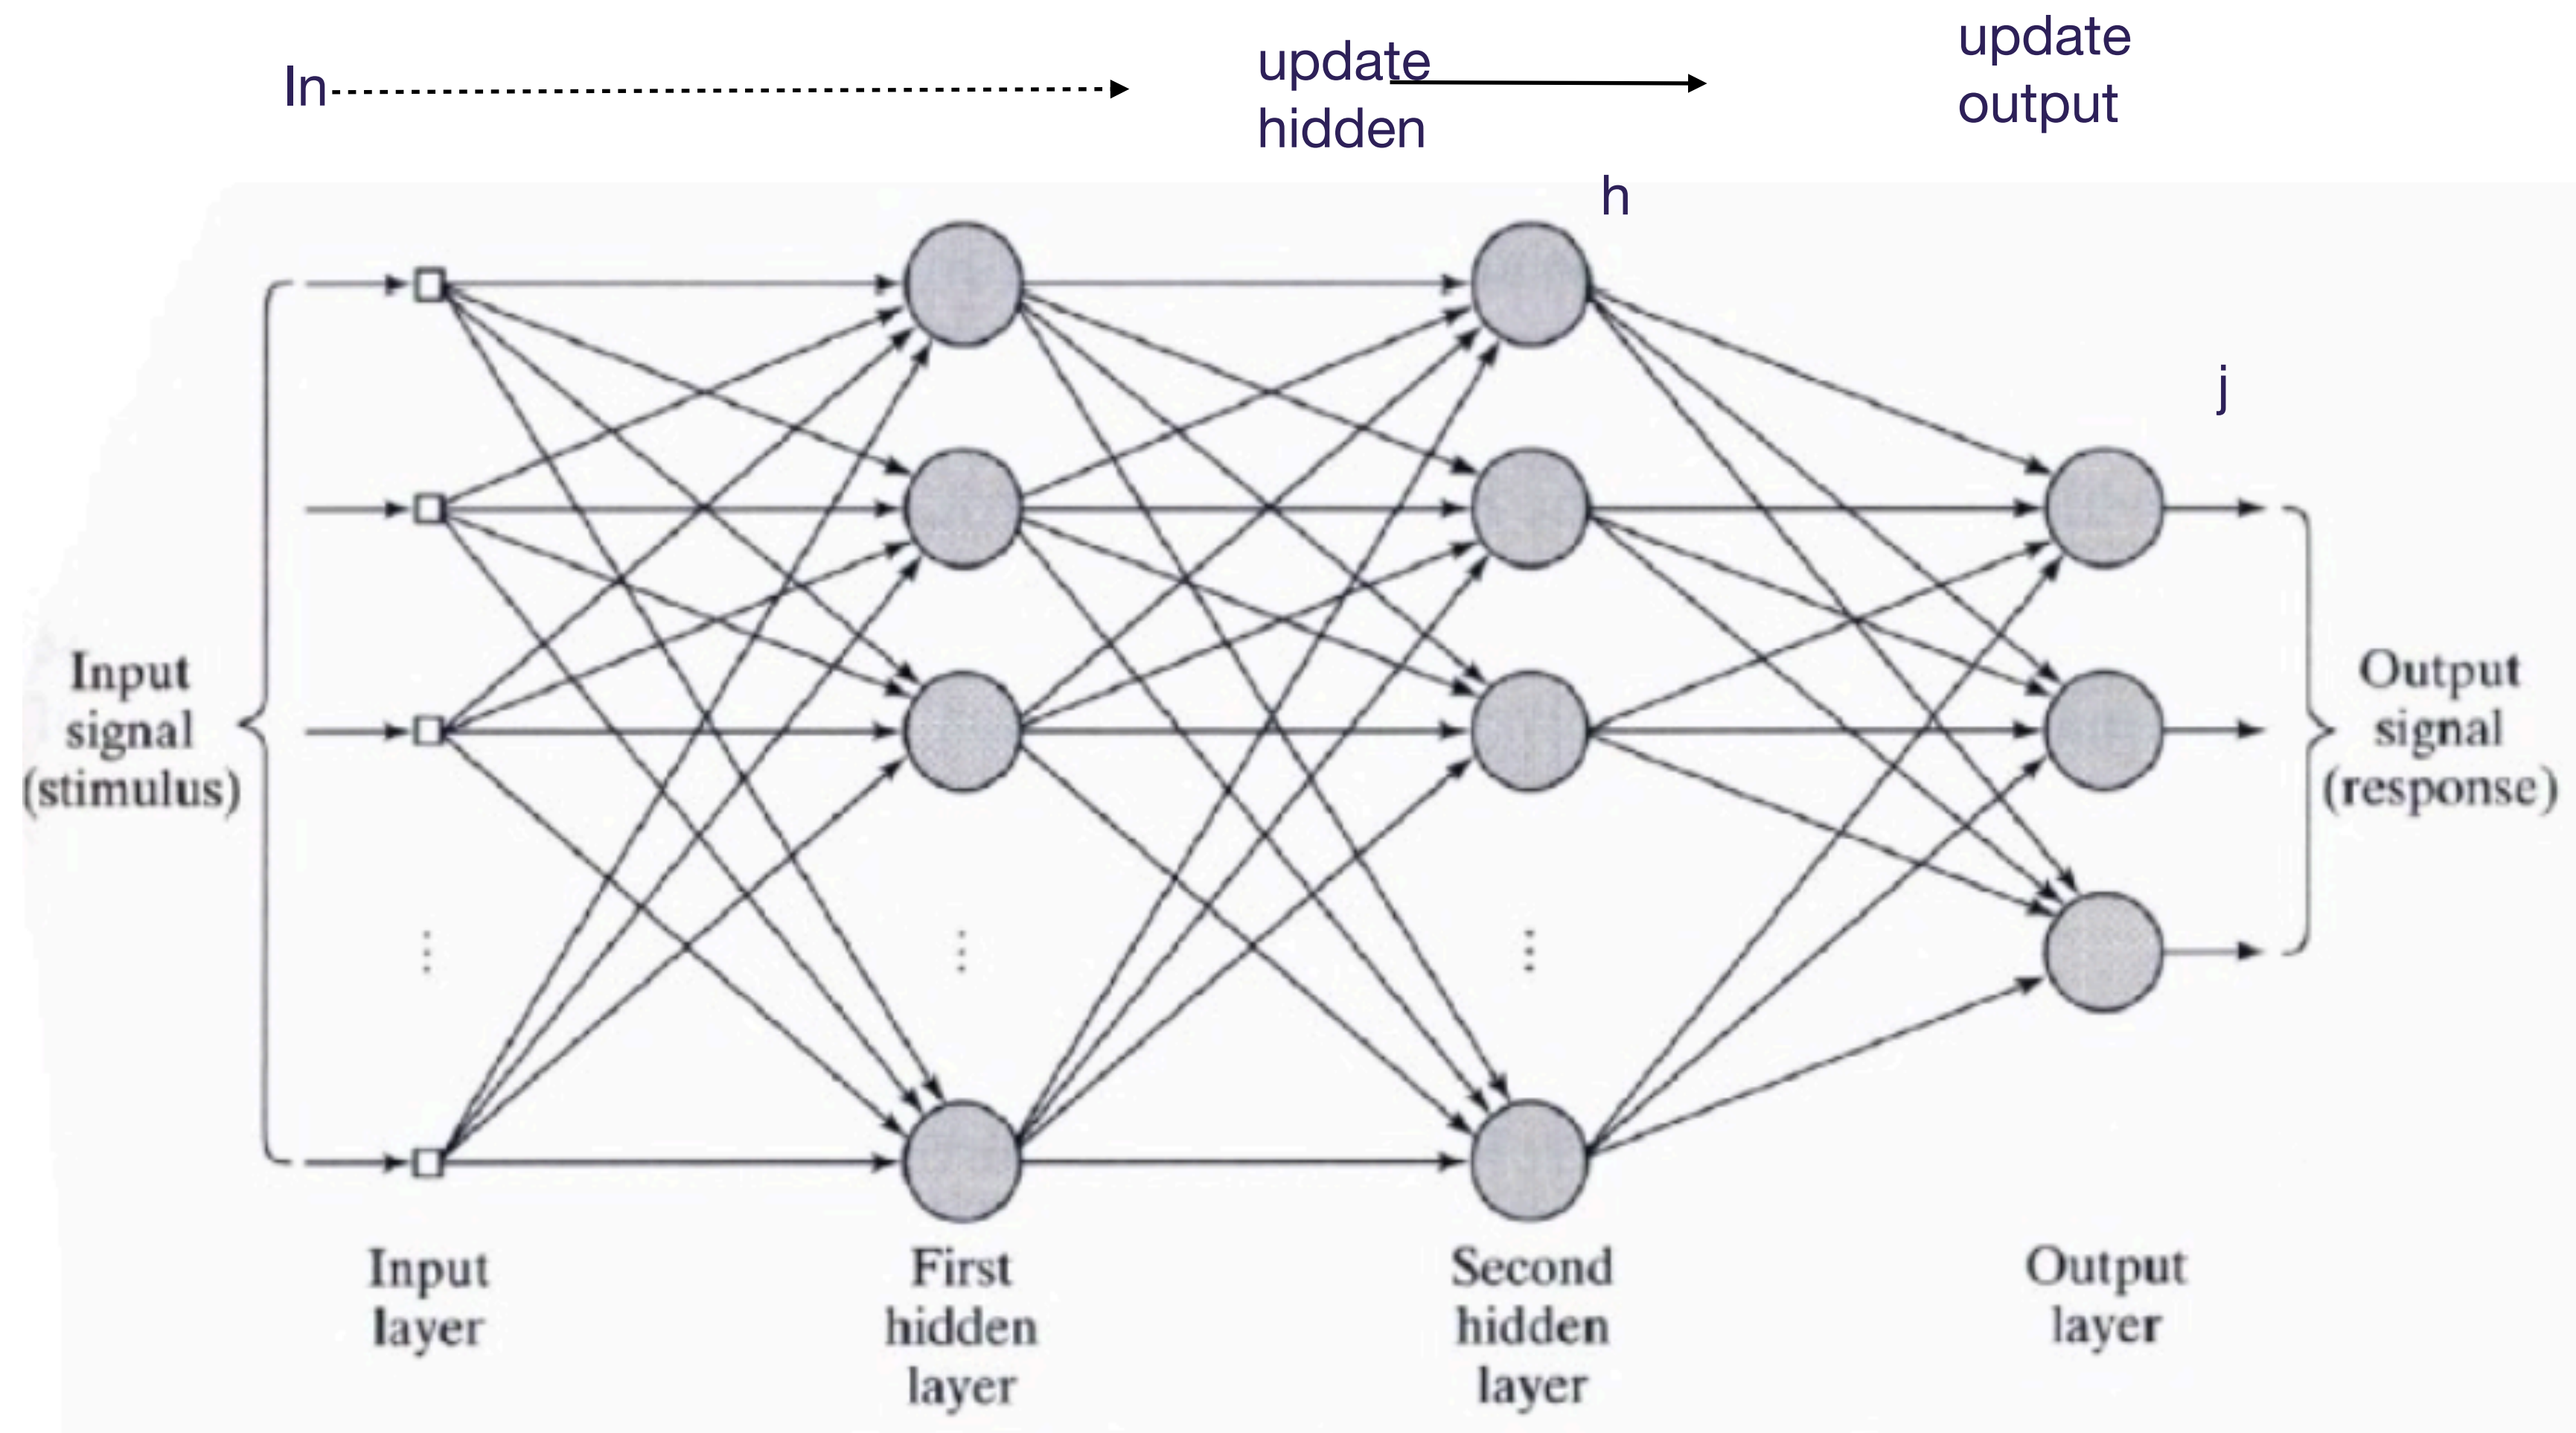




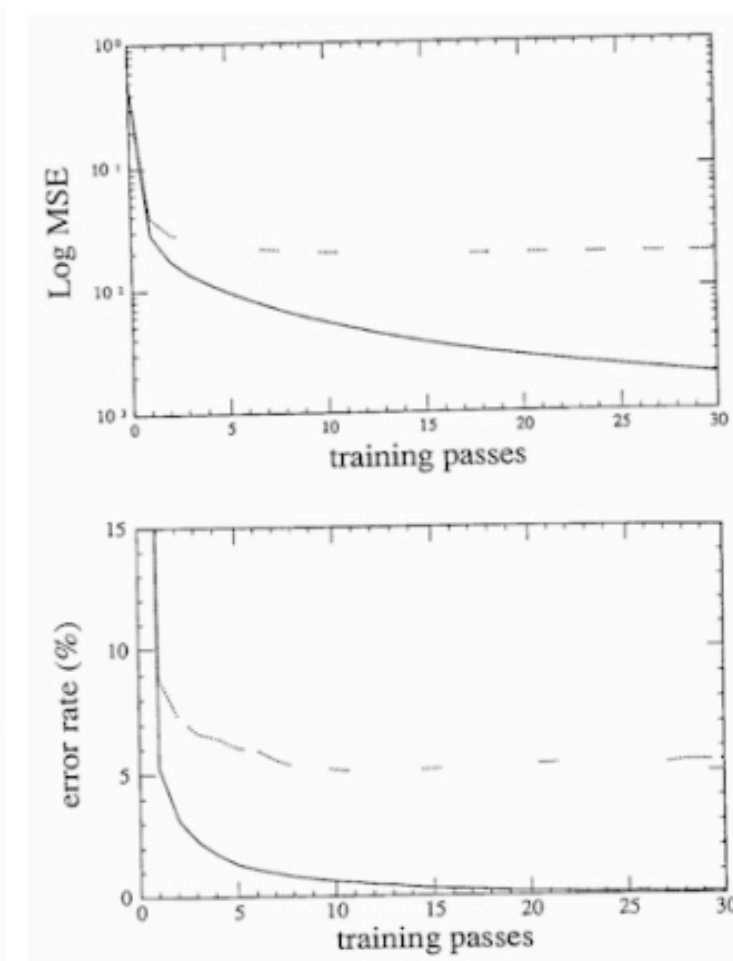



Base MNIST


- 60 000 caractères « train »
- 10 000 caractères « test »

back - propagation





back - propagation



Y_d




Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation





Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation





Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation





Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation





Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation





Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation






Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).

back - propagation



Yd


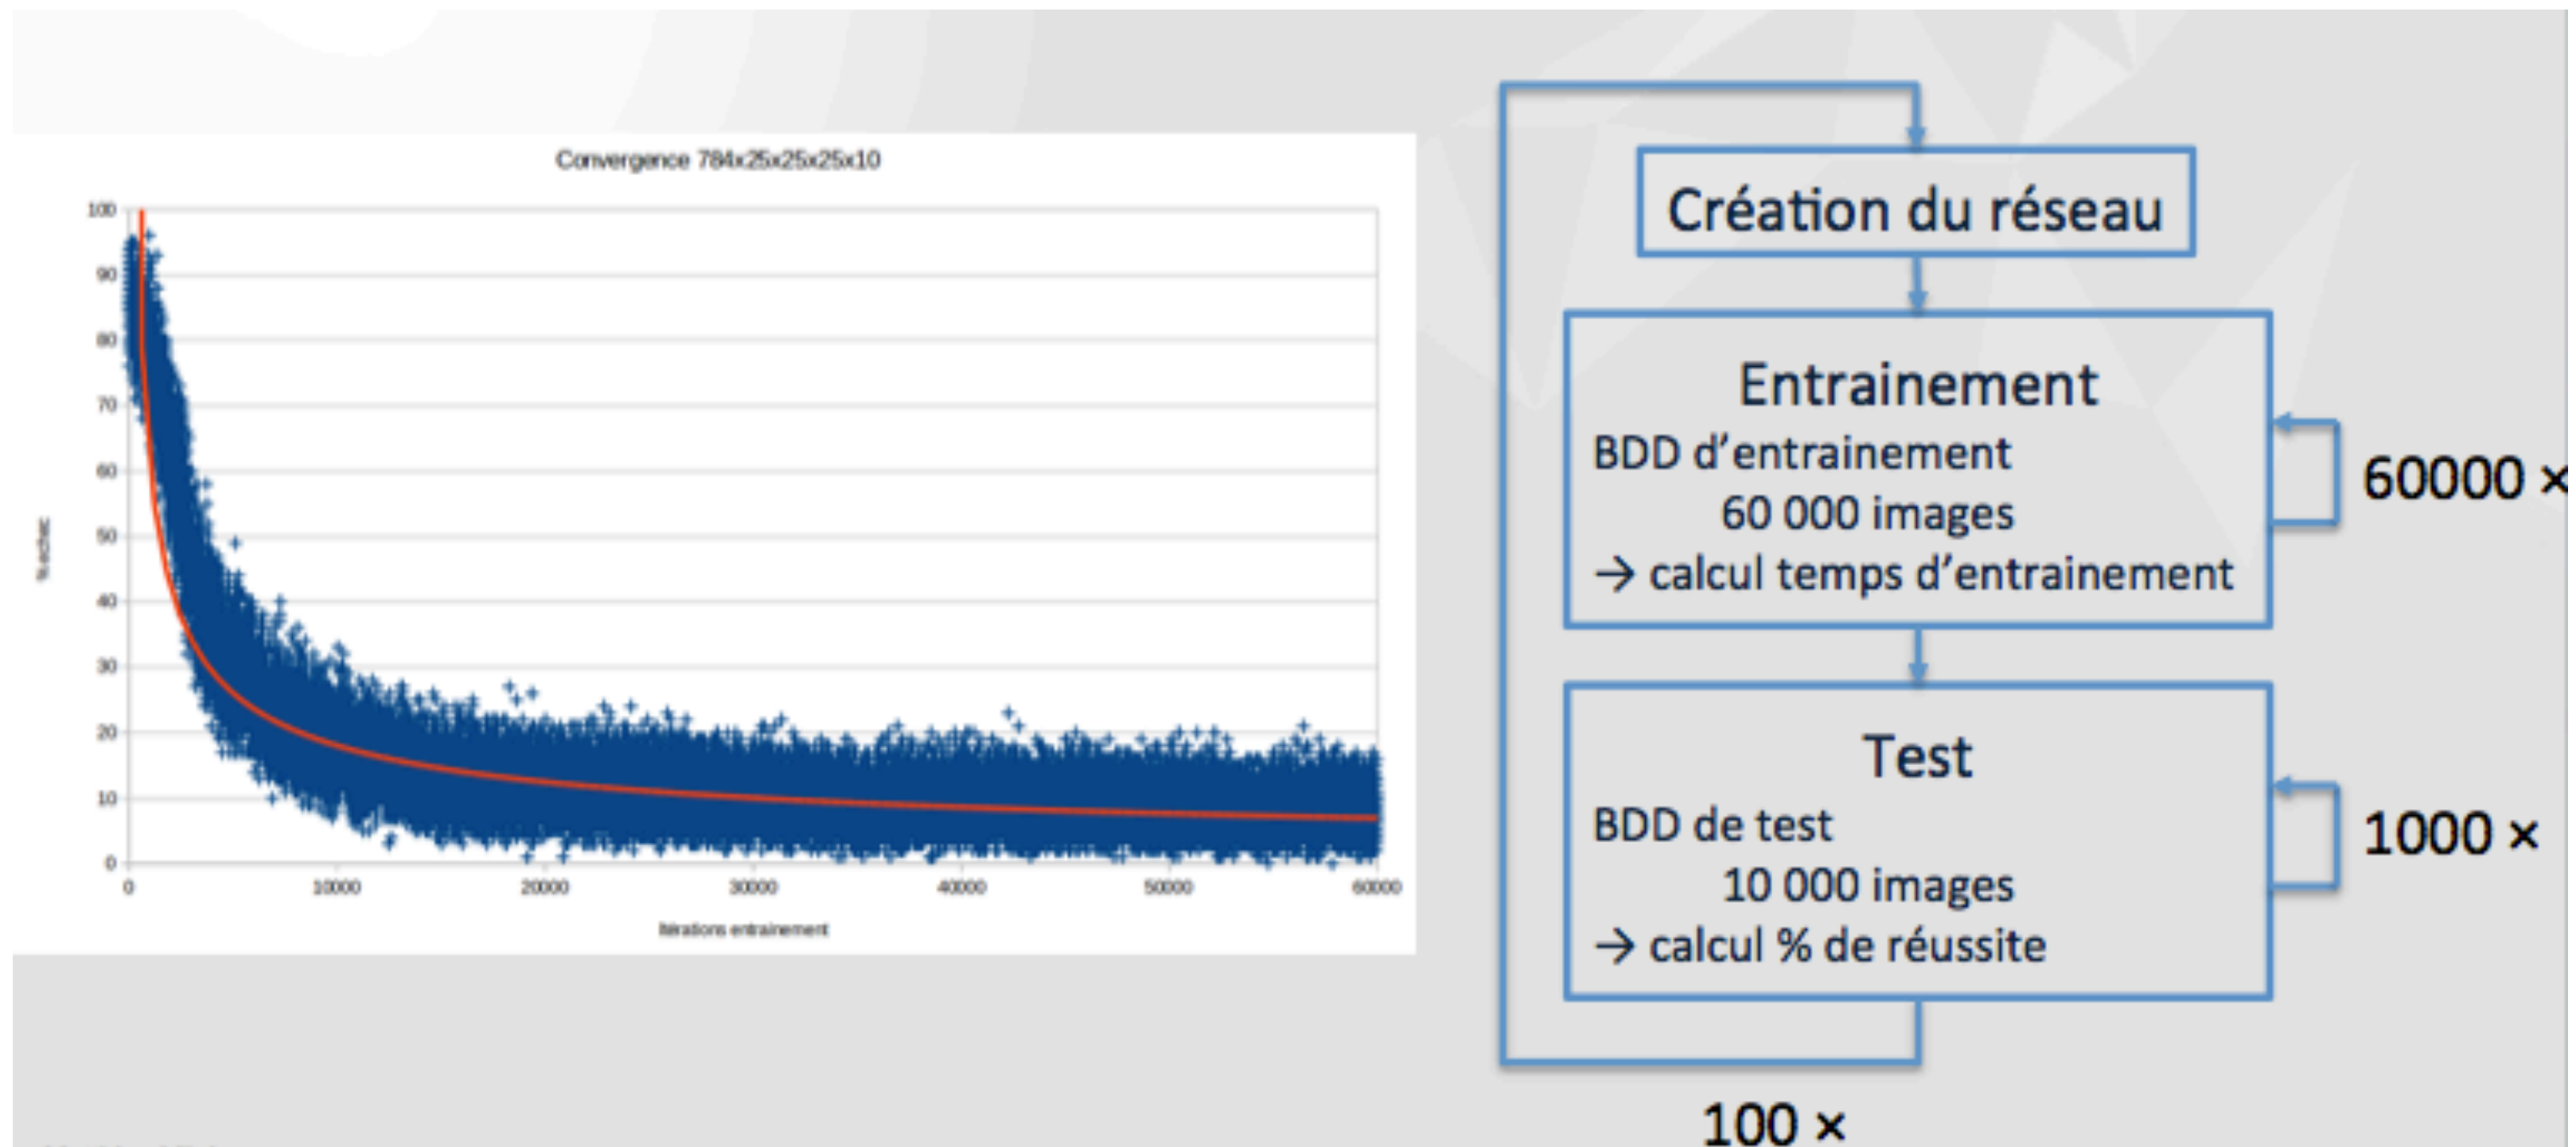


Fig. 7.1. Three sigmoids (for $c = 1$, $c = 2$ and $c = 3$)

Algorithme

1. Choisir une classe au hasard, c'est à dire un motif parmi les 60000 de la base d'entrainement. Charger le motif et mémoriser le Y_d^k correspondant au label (label de la base d'entrainement).
2. Propager sur la rétine : $X_j = \text{Pix}_j / 255$.
3. Calculer la sortie des neurones de la couche cachée: $X_h = f(\text{pot}_h)$
 $\text{pot}_h = \sum_j W_{hj} X_j$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
4. Calculer la sortie des neurones de la couche de sortie: $X_i = f(\text{pot}_i)$
 $\text{pot}_i = \sum_h W_{ih} X_h$ avec $f(x) = \frac{1}{1+e^{-x}}$, dérivable et continue.
5. Pour chaque neurone de la couche de sortie : $\delta_i = f'(\text{pot}_i) \cdot Y_d^k - X_i$ remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
6. Pour chaque neurone de la couche cachée : $\delta_h = f'(\text{pot}_h) \cdot \sum_i \delta_i \cdot W_{hi}$
 remarque : $f(x)$ est dérivable et continue, on a $f'(x) = f(x) \cdot (1 - f(x))$
7. Apprendre : $W_{ij}(t+1) = W_{ij}(t) + \epsilon \cdot \delta_i \cdot X_j$
8. Calculer le pourcentage d'erreur sur p (par exemple $p = 100$) motifs pris au hasard dans la base d'entrainement présentés $Err = \frac{\sum_p \sum_i |\delta_i|}{p}$. si $Err > \text{seuil}$ aller à l'étape 1, sinon fin (on doit normalement pouvoir atteindre un seuil de 96% de bonnes réponses sur la base de test).


back - propagation




Applications

- The properties of neural networks define where they are useful.
 - Can learn complex mappings from inputs to outputs, based solely on samples
 - Difficult to analyse: firm predictions about neural network behaviour difficult:
 - Unsuitable for safety-critical applications.
 - Require limited understanding from trainer, who can be guided by heuristics.

Applications



Applications



- NN are able to generalise
- learning involves generating a partitioning of the input space
- for single layer network input space must be linearly separable
- what is the dimension of this input space?
- how many points in the input space?
- this network is binary(uses binary values)
- networks may also be continuous

Applications



ALVINN

Drives 70 mph on a public highway



30 outputs
for steering
4 hidden
units

30x32 pixels
as inputs



30x32 weights
into one out of
four hidden
unit